BIG DATA

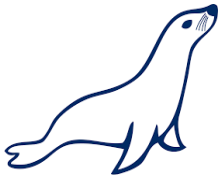
Osman AIDEL





Responsable Bases De Données

- Mariadb



- PostgreSQL



- MySQL



- Oracle

ORACLE

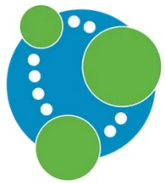
- ElasticSearch



- MongoDB



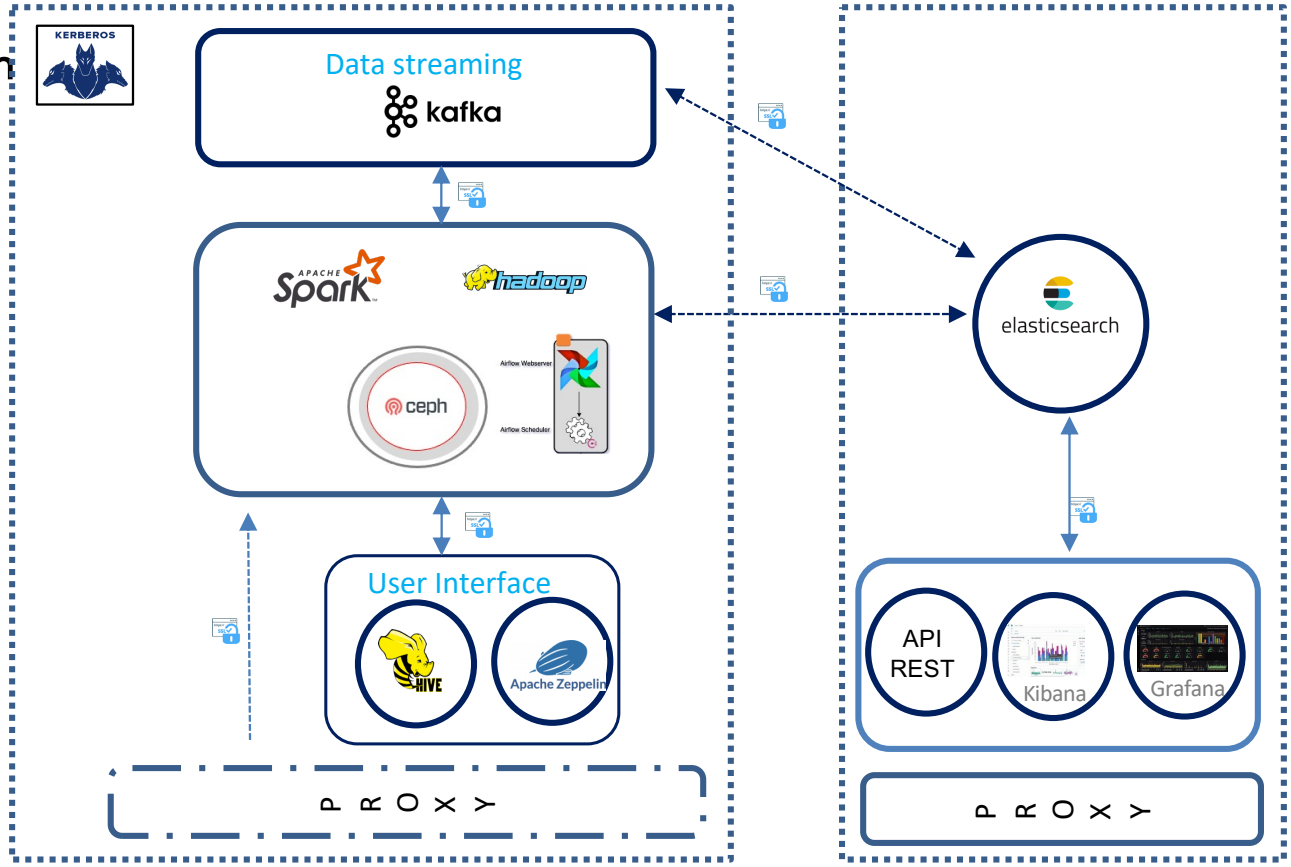
- Neo4J

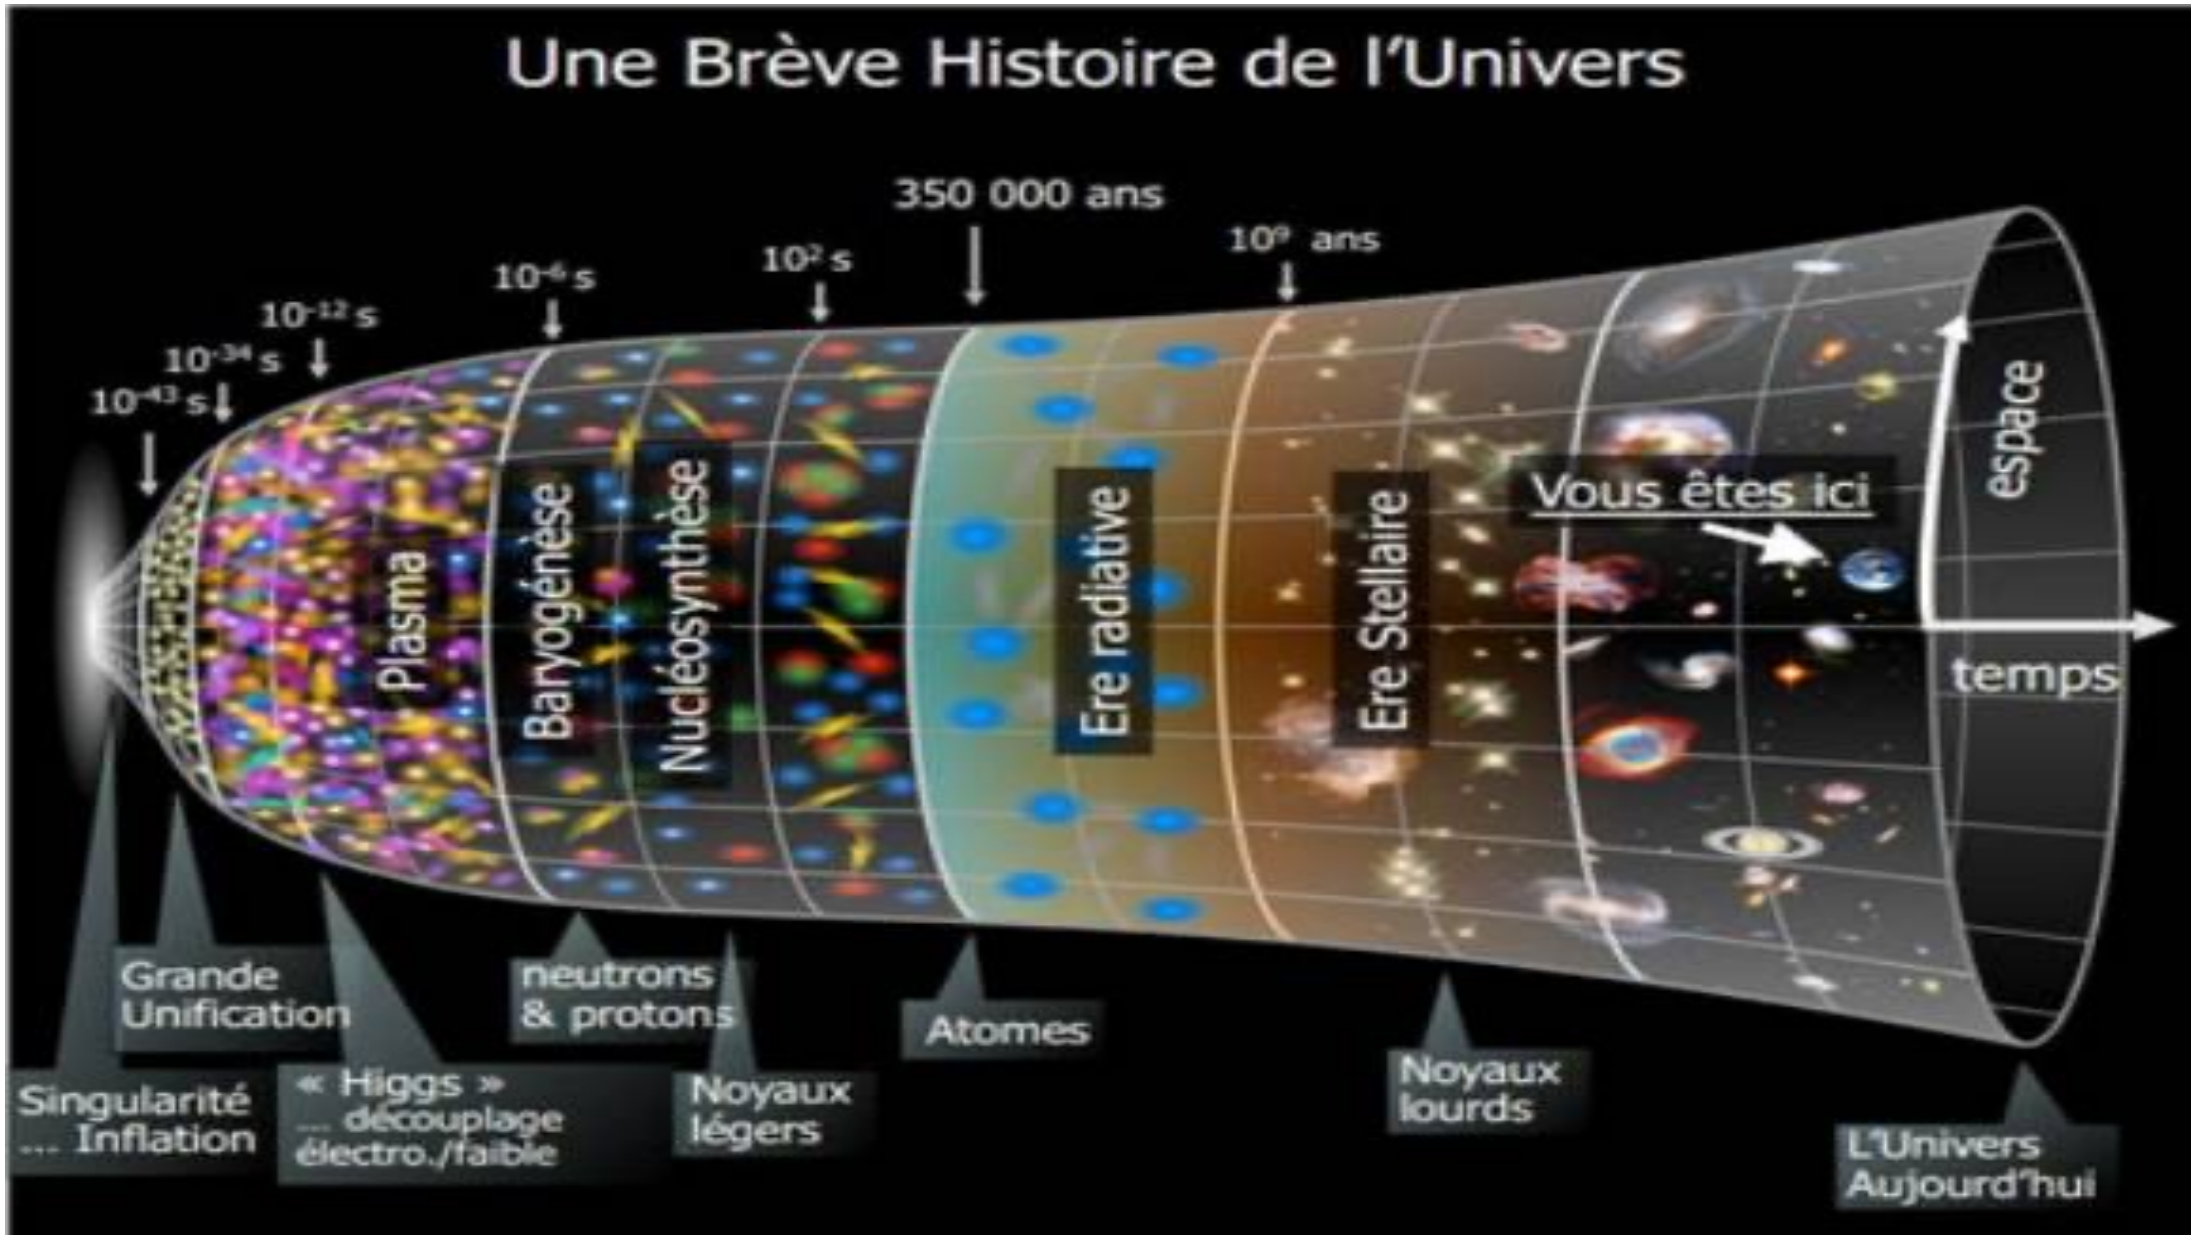


Plus de 1 000 bases de données :
Volumétrie > 50 To
32 serveurs de bases de données

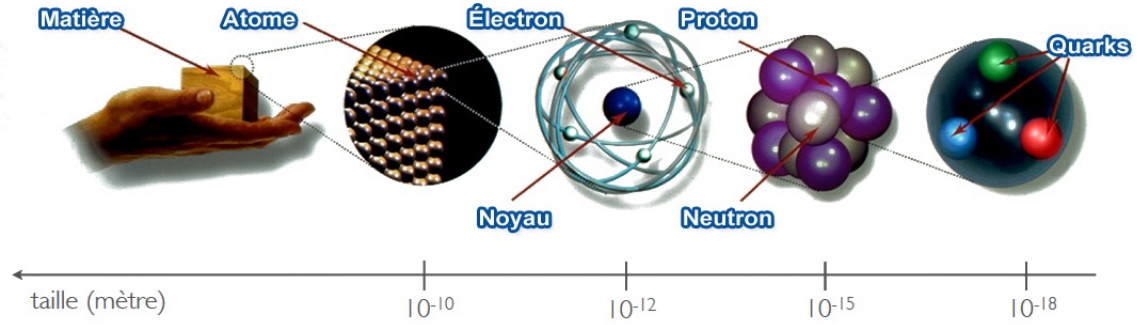


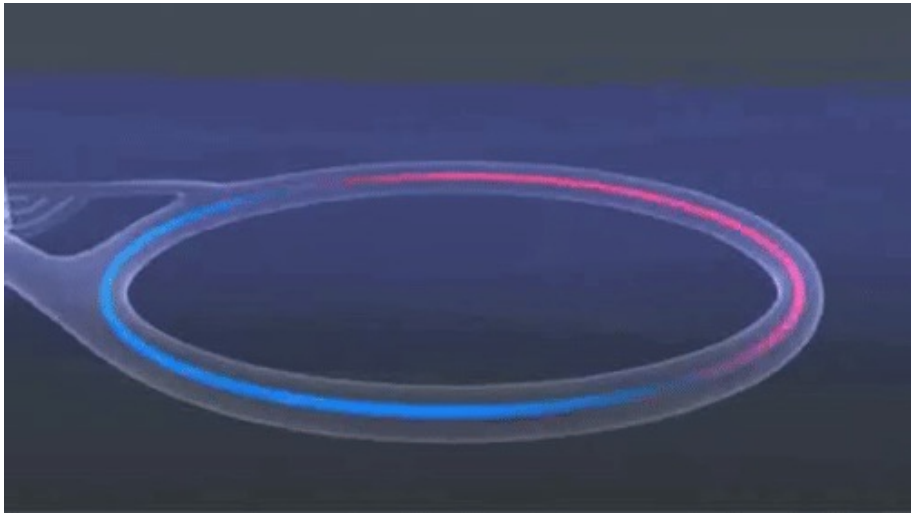
Data Platform



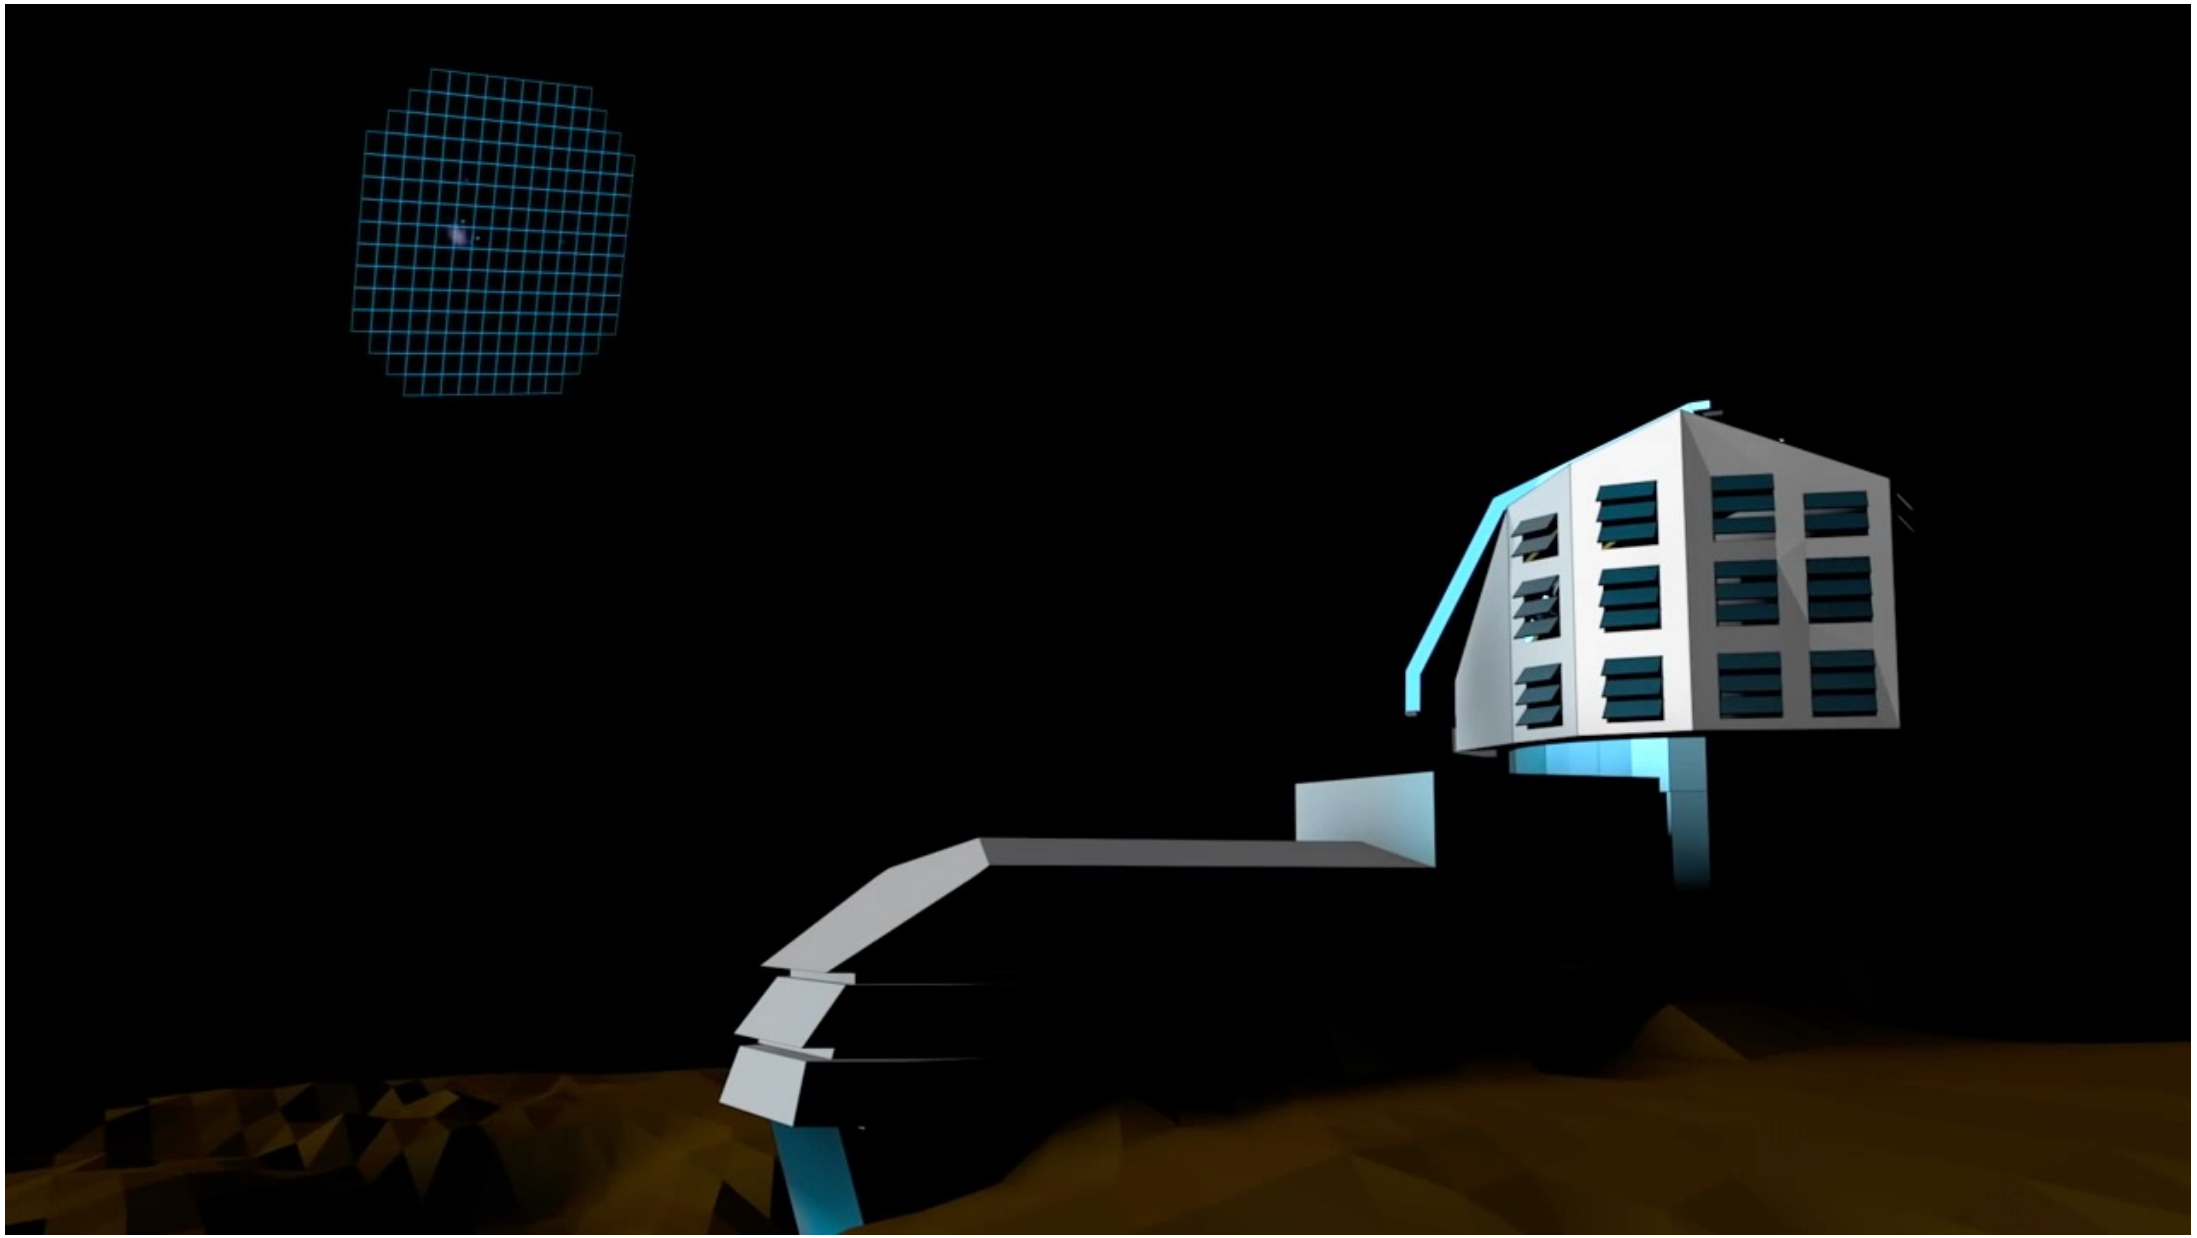

Une Brève Histoire de l'Univers
350 000 ans
10^{9} ans
10^{2} s
10^{-6} s
10^{-12} s
10^{-34} s
10^{-43} s
Plasma
Baryogénèse
Nucléosynthèse
Ere radiative
Ere Stellaire
Vous êtes ici
espace
temps
Grande Unification
Singularité ... Inflation
« Higgs » ... découplage électro./faible
neutrons & protons
Noyaux légers
Atomes
Noyaux lourds
L'Univers Aujourd'hui

Les expériences Large Hadron Collider





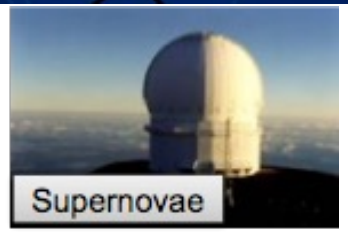

COLLISION EVENT IN THE ATLAS DETECTOR



Les expérier



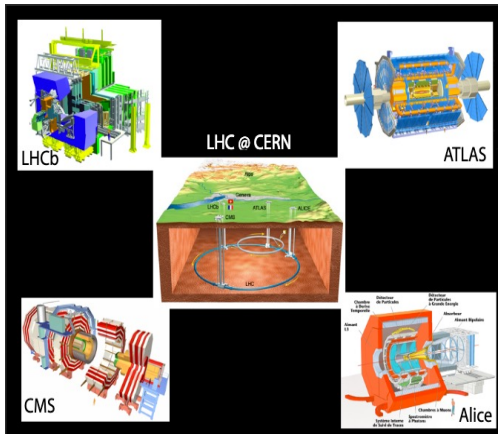




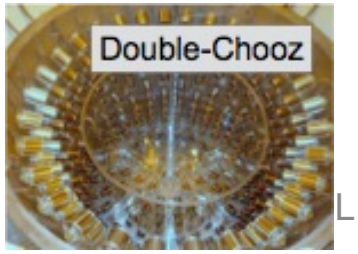












L







Programme



0 Pourquoi le BIG DATA

1 Environnement de travail

2 Le monde NoSQL

3 Les bases Graphe

4 Les bases Document

5 Les bases Clé-Valeur

Programme



5

6

7

Introduction



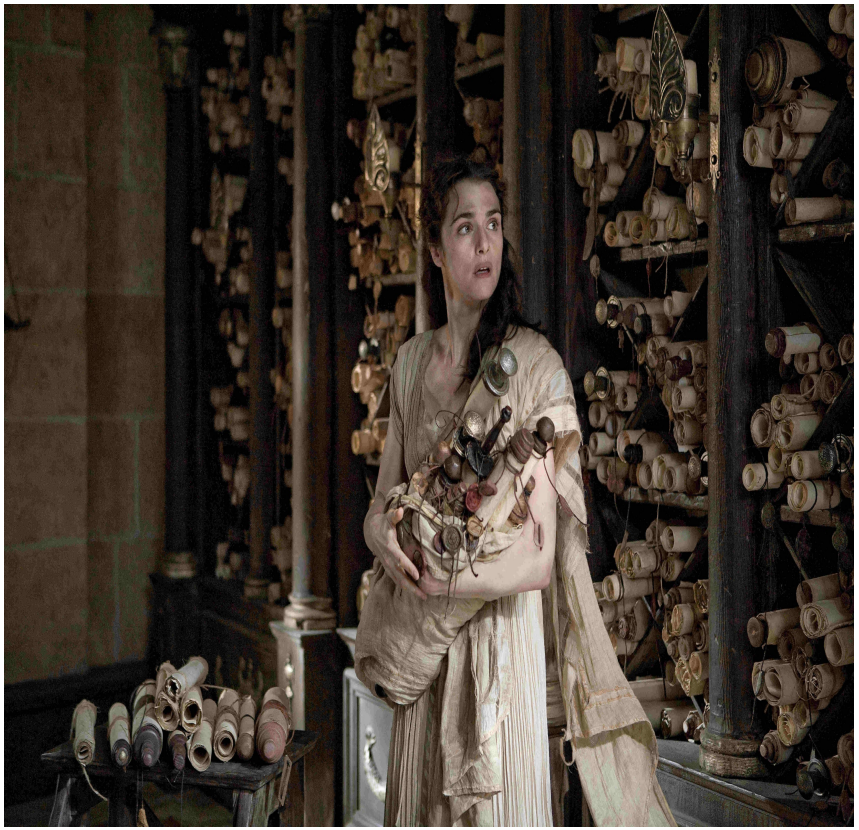
1 – Le début de l’informatique

2 – L’évolution des technologies



Qu'est-ce qu'une base de données ?

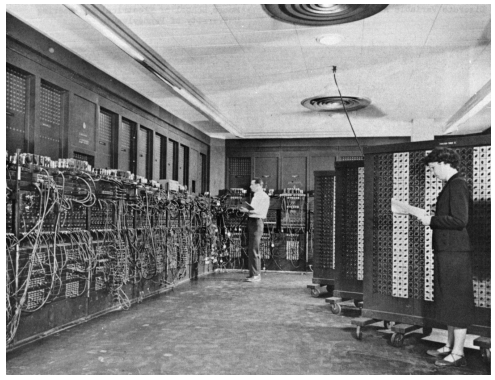
- Centraliser les données
- Collecter et stocker les données
- Organiser les données pour faciliter la recherche



Les défis technologiques

Le premier calculateur est né en 1946

- ENIAC : ***Electronic Numerical Integrator And Computer***
- 400 flops
- 167 m^2
- 30 Tonnes



1955 : Stockage par bande magnétique



Et votre smartphone ???



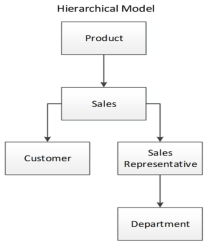
Smartphone 2022 :

- Stockage 1To
- 400 Gflops

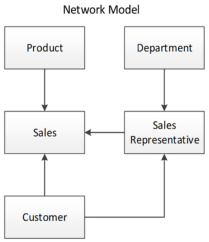


Première génération de bases de données : 1950 - 1970

- **1965 : Modèle hiérarchique**



- **1969 : Modèle Réseau**



Connu comme base de données de navigation. On navigue entre les objets par des liens/pointeurs.
Pas pratique à manipuler.

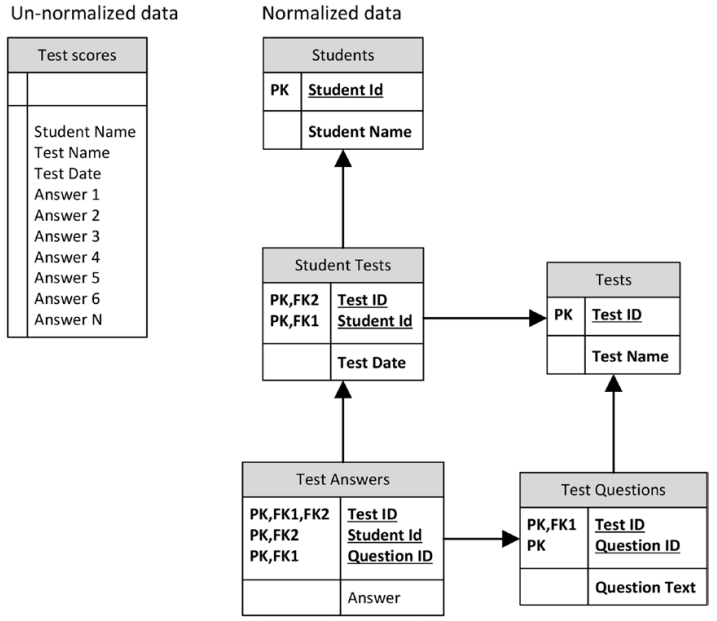
Seconde génération des bases de données

1970 : Le modèle relationnel a fait son apparition avec la publication du Dr Edgar Codd (chercheur IBM)

Un modèle reposant sur une théorie mathématique : l'algèbre relationnel.

Les données sont regroupées dans des tables à 2 dimensions avec des lignes et des colonnes.

Un modèle normalisé afin d'éviter les incohérences de données.



Seconde génération des bases de données



Le modèle relationnel définit la manière d'organiser les données mais il ne définit pas la manière dont la base de données gère les accès concurrents.

Le Dr Jim Gray va proposer un modèle transactionnel ou une transaction est définit comme un ensemble de modifications laquelle dispose des proriétés suivantes :

- **Atomicité** : Une transaction est indivisible. Soit toutes les modifications dans la transaction sont appliquées soit aucune.
- **Cohérence** : La base de données reste dans un état cohérent avant et après application d'une transaction.
- **Isolation** : Plusieurs transactions peuvent être traitées simultannément.
- **Durabilité** : Une fois une transaction est appliquée (COMMIT), les changements sont conservés même en cas de panne.

Seconde génération des bases de données



Les bases de données relationnelles

Avantages :

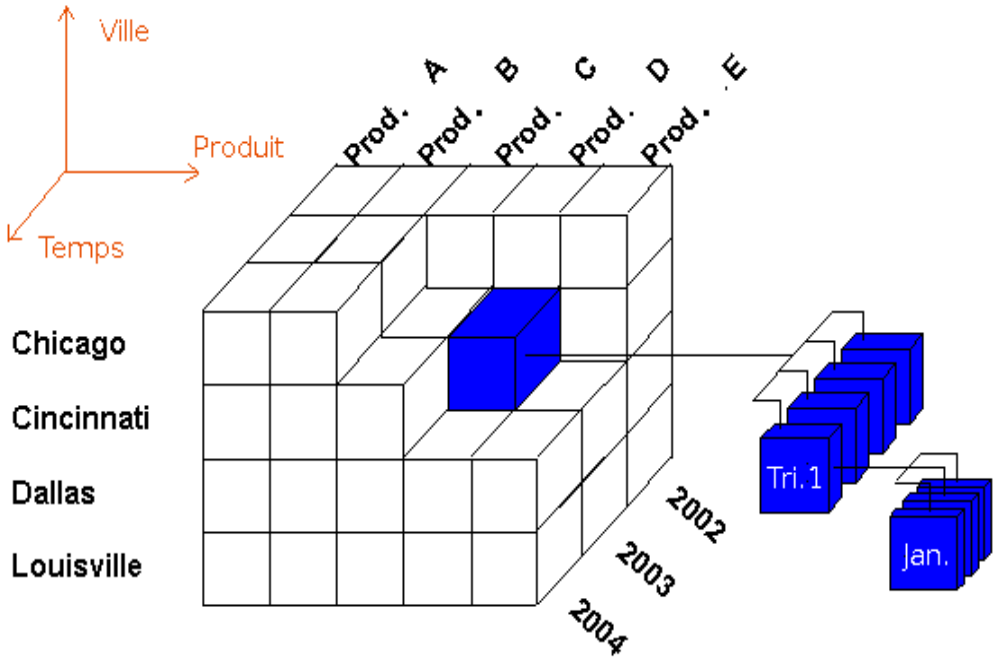
- ✓ La technologie est mature (création il y a plusieurs dizaines d'années) ce qui fait qu'aujourd'hui le SQL est un langage standard et normalisé.
- ✓ On a une garantie que les transactions sont atomiques, cohérentes, isolées et durables – principe ACID (Atomic, Consistent, Independant, Durable).
- ✓ La possibilité de mettre en œuvre des requêtes complexes (croisement multiple des données)
- ✓ Du fait du nombres d'années d'existence, un large support est disponible et il existe également de fortes communautés.

Inconvénients :

- La modification du modèle de données peut être couteuse.
- L'évolution des performances est verticale (augmentation des ressources du serveur).
- Sur un très grand volume de données (centaines-milliers de Tera octets) le modèle peut atteindre des limites en terme de performance
- Pour certains éditeurs, le prix de licence est élevé.

Seconde génération des bases de données

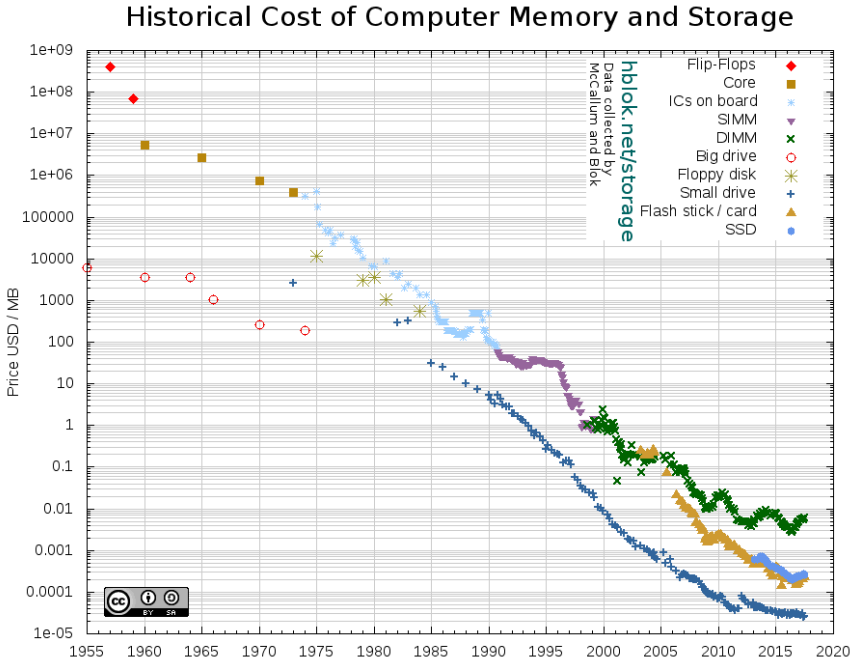
- Les entrepôt de données (Dataware house)



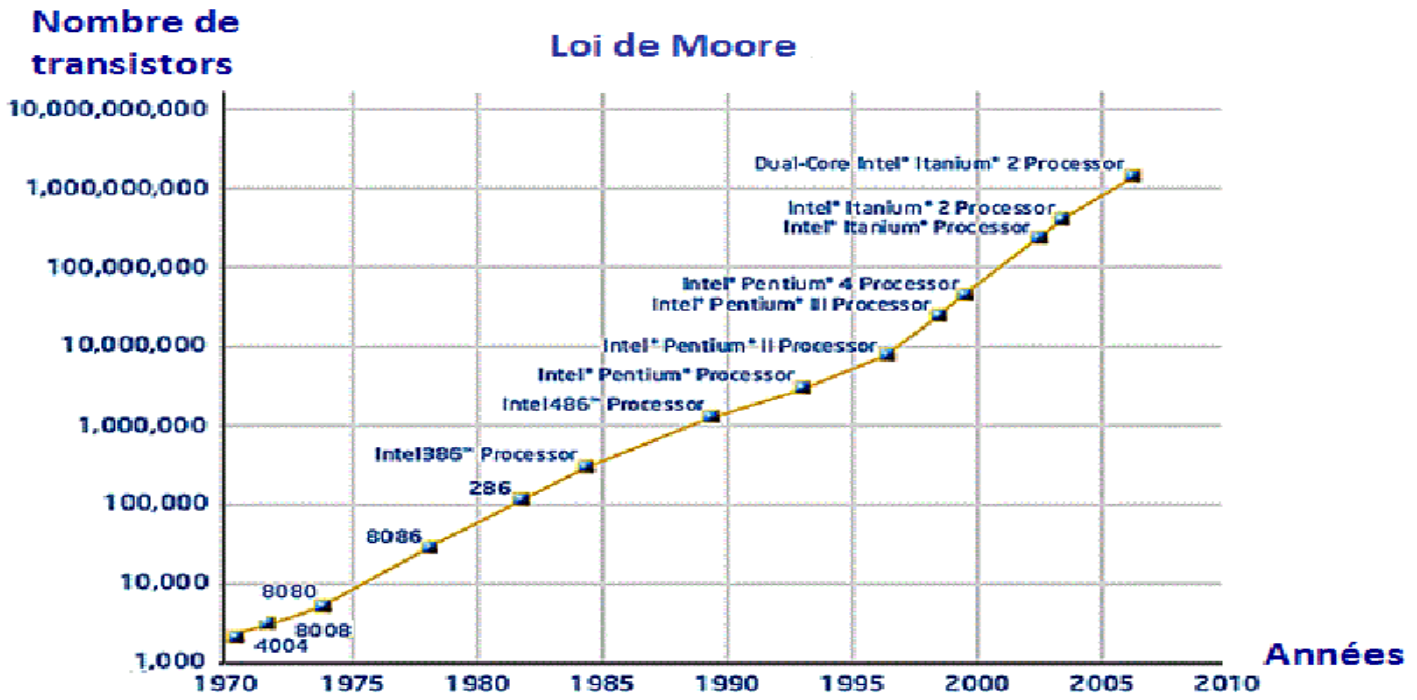


L’évolution matérielle

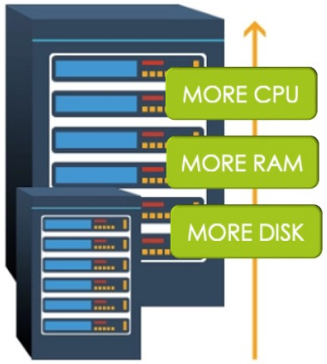
- La marginalisation du matériel converge avec les ambitions du BIG DATA.
- A partir des années 2000, le matériel devient accessible à tous.



L’évolution matérielle



Le besoin



Vertical Scaling
(Scaling up)

- Tous les géants d'internet tel que Google, Facebook, Amazon etc… sont confrontés aux problématiques de traitements de grosses volumétries.
- La plupart des données est accédée à partir de bases de données relationnelles.
- Malheureusement, plus le volume de données est important et plus les bases de données traditionnelles atteignent leurs limites et deviennent de plus en plus lentes.
- L'approche par extensibilité verticale (matériel plus performant) atteint ses limites et est trés coûteuse.
- Les applications web passent à l'echelle mais les bases de données relationnelles restent le goulot d'étranglement.
- Pour répondre à la charge croissante des applications web, les SGBDR mettent en place des systèmes de replication pour les accès en lecture seulement. Les écritures sont toujours concentrées vers une seule machine.



Le besoin



Le besoin : Forensic



Le besoin : Profiling

VOUS



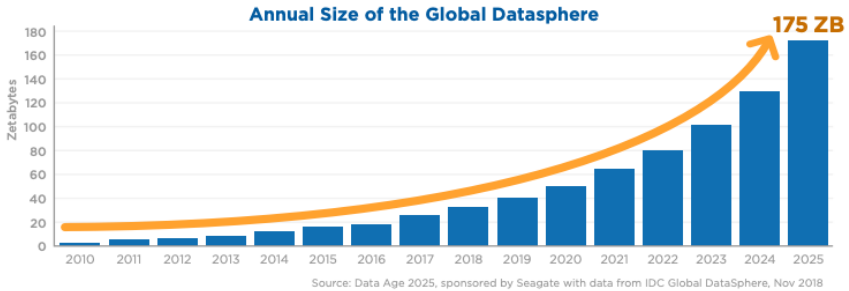
Le besoin : Prédiction / IA

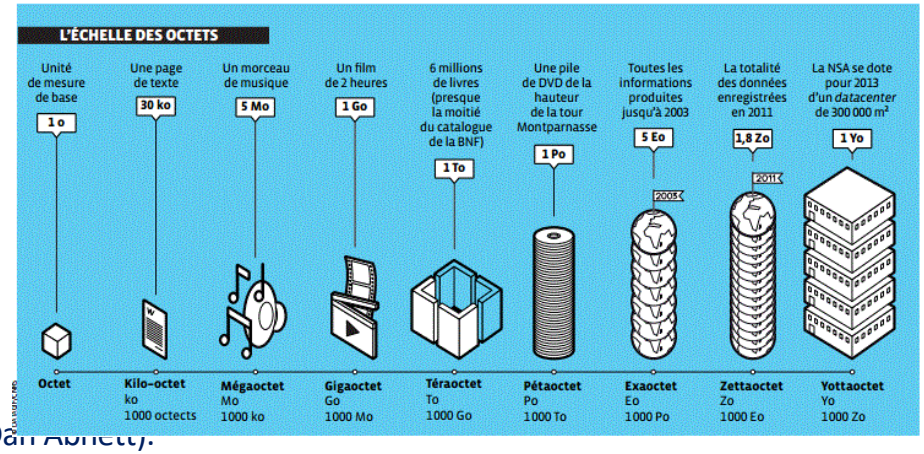


Le besoin

Des volumétries astronomiques sont en jeux :

Figure 1 – Annual Size of the Global Datasphere





– Le savoir est dans les données et « Le savoir, c'est le pouvoir » (Dan Ariely).

– Aider les compagnies / la science à mieux comprendre leur métier / notre univers.

– A mieux comprendre les clients.

– Découvrir de nouvelles logiques métiers.

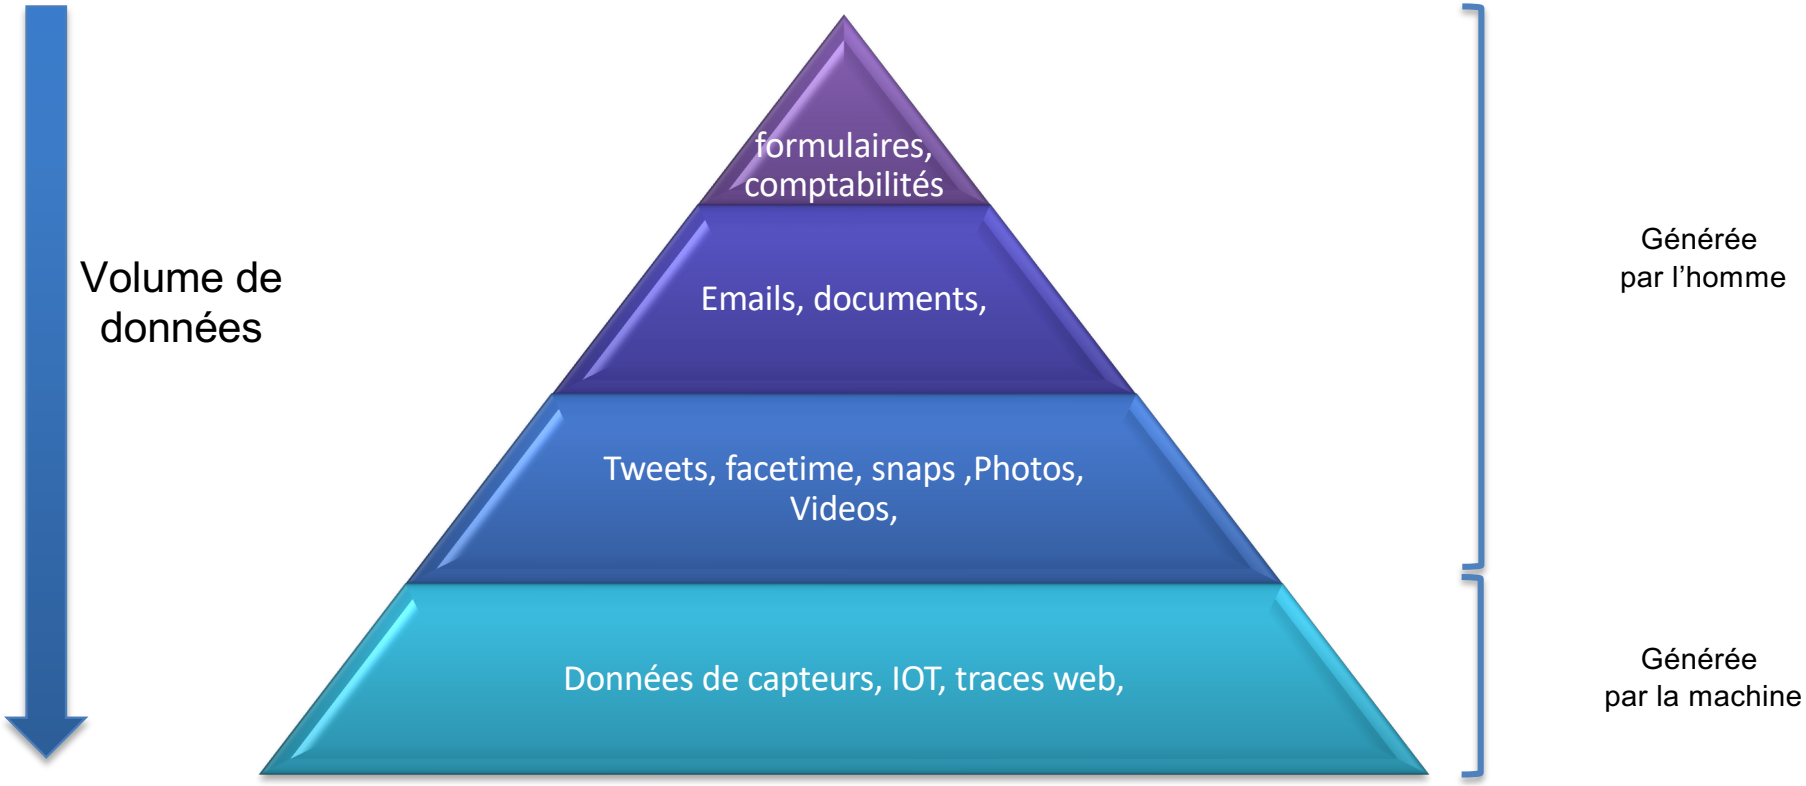
– Prendre de rapides et de bonnes décisions.

– En 2019, les données ont une valeur non négligeable.

– Pour certains, la croissance des données de l'entreprise est un facteur de développement.

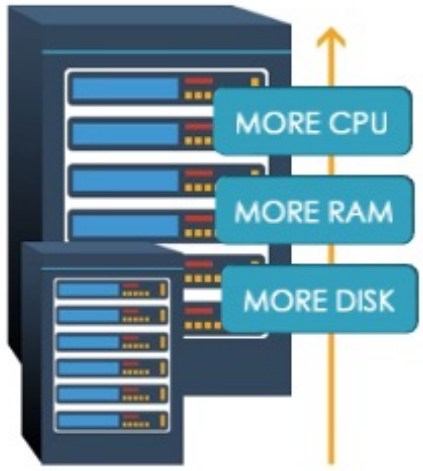

BIG DATA

Les défis technologiques



Les architectures distribuées

- Une alternative à cette approche est de basculer à une architecture horizontale.
- « Diviser pour mieux régner »



Vertical Scaling
(Scaling up)



Horizontal Scaling
(Scaling out)

modèle MPP (Massively parallel processing)
où
shared nothing.

Les architectures distribuées

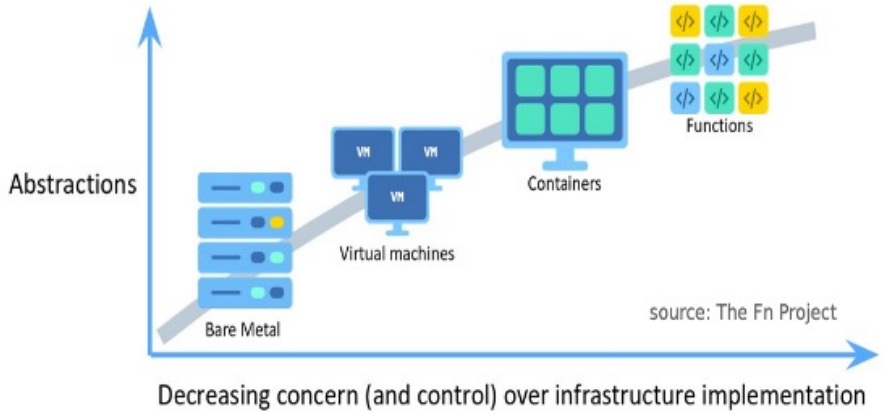
Les technologies de virtualisation offrent aux entreprises une flexibilité plus accrues dans l'architecture des systèmes informatique et la gestion des coûts.

L'internet favorise par son réseau la distribution des environnements informatique.

Avec le cloud, les environnements se dimensionnent à la demande et le nombre, le volume et la variété des données augmentent très rapidement.

- Abandon des applications monolithiques pour des applications plus nombreuses, interropérable, hétérogènes et extensibles.

- Les applications sont à présent conçu nativement pour être scalable.





Les architectures distribuées

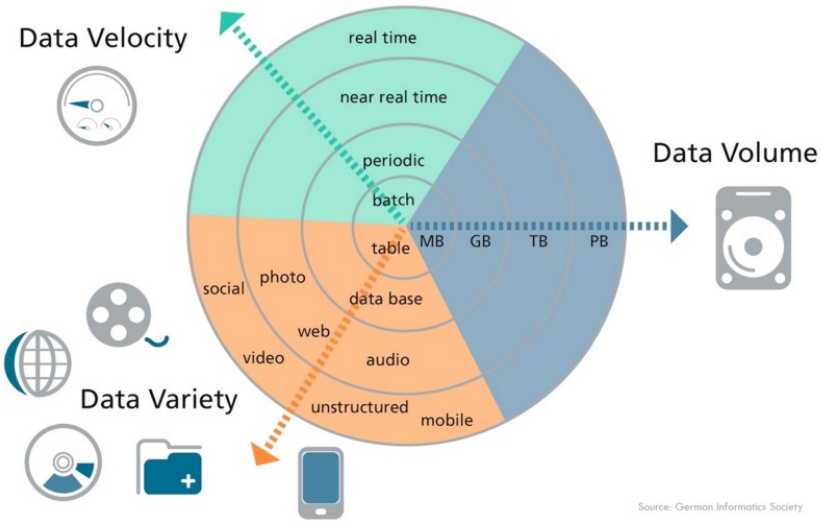


La tendance BIG DATA

- Il n’y a pas de définition officielle du BIG DATA.

- BIG DATA fait référence aux situations où les ressources matérielles existantes ne sont pas suffisantes pour le traitement des données.

- La définition de BIG DATA selon Gartner est connue sous le nom de la règle des 3V :
  - Volume
  - Vélocité
  - Variété



La tendance BIG DATA

❑ Volume

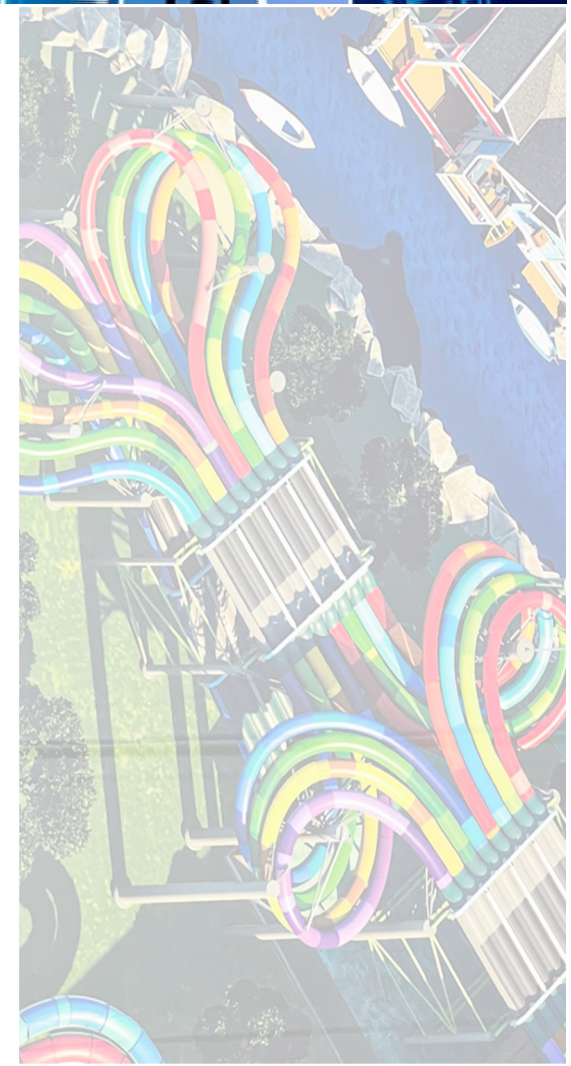
- Le volume réfère au montant de données générées où stockées.
- Le volume est généralement la principale composante qui détermine l'adoption de solutions BIG DATA d'ou le nom.
- Le volume peut s'exprimer en quelques gros fichiers où des milliers de petits fichiers.
- L'idée est de traiter les données en un temps « raisonnable » quelque soit la quantité de données.



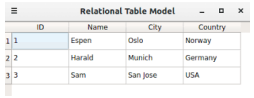
La tendance BIG DATA

❑ Vélocité

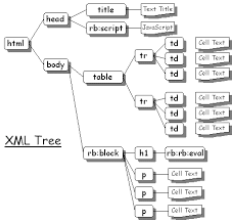
- **Vélocité** réfère à la vitesse à laquelle les nouvelles données sont générées.
- Les technologies de BIG DATA nous permettent aujourd'hui d'analyser les données alors qu'elles viennent d'être générées.
- Les données sont générées à grande vitesse et peuvent avoir des structures différentes.
- Ces aspects sont des défis majeurs qui couplés à des grosses volumétries rendent les systèmes de traitements de données existant inappropriés.
- Dans une base de données relationnelle, modifier la structure des données revient à reconcevoir le modèle de données.



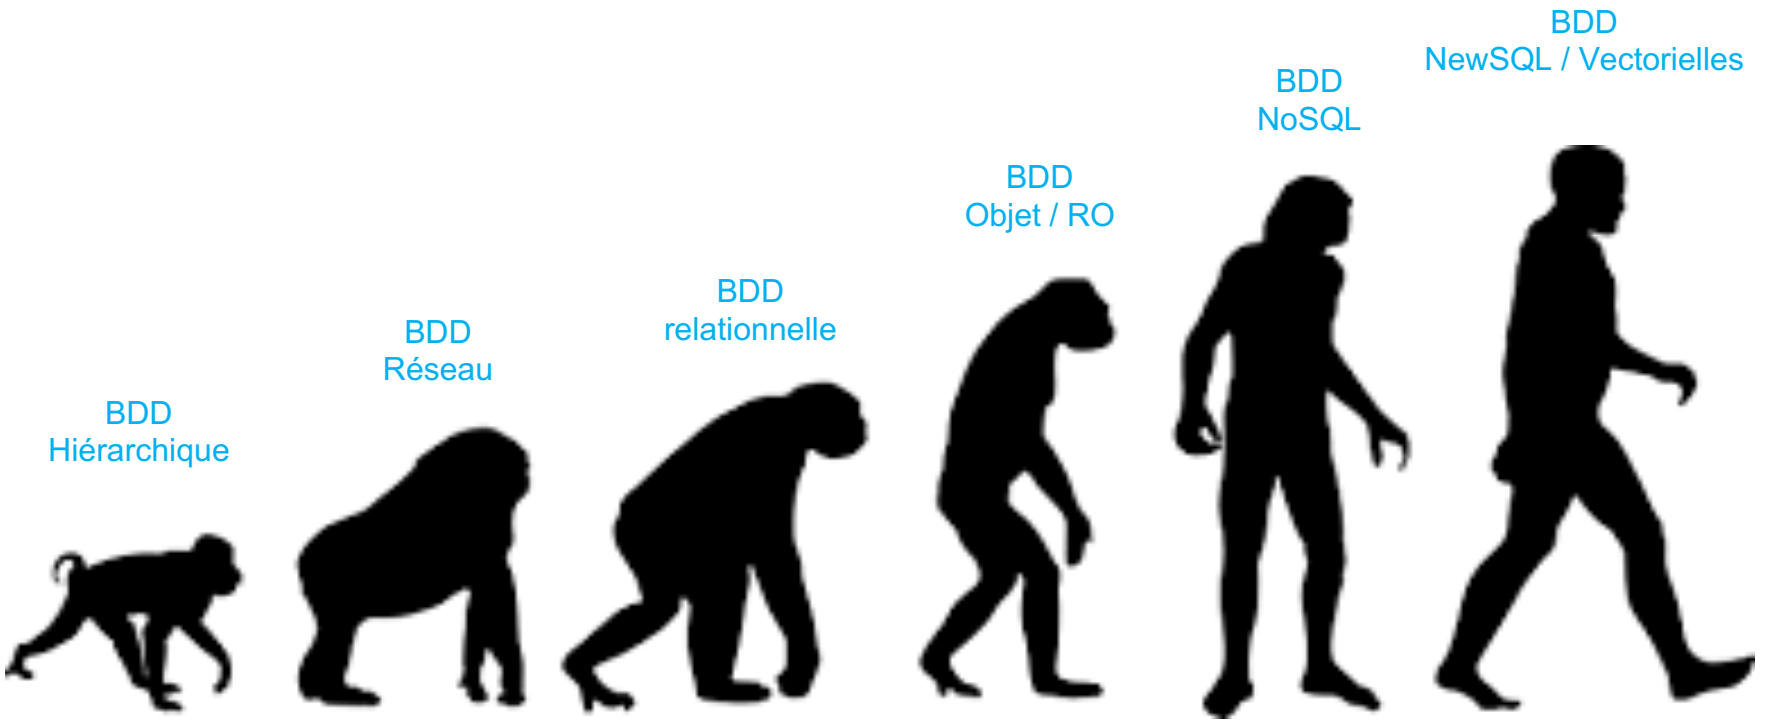
La tendance BIG DATA



- Variété
  - **Données structurées**
    - Les données sont stockées sous une structure définie.
    - Le type et la taille de chaque information sont connus.
    - Les données peuvent être accédées et traitées à partir d'un langage.
    - Exemple : les tables relationnelles.
  - **Données non-structurées**
    - Les données avec un format inconnu.
    - Les données ne suivent aucune règle ou pattern.
    - Il n'y a pas de langage qui permette de les exploiter.
    - La taille d'une donnée est variable et peut être massive.
    - Exemple : vidéo, image, un long texte …
  - **Données semi-structurées:**
    - Elles ont une structure.
    - Les données sont basées sur une sémantique auto-descriptive.
    - La même information peut être classifiée avec différentes taille et types.
    - Les données peuvent être accédées et traitées à partir d'un langage.
    - Exemple : les données d'une station météo (XML ou JSON) …



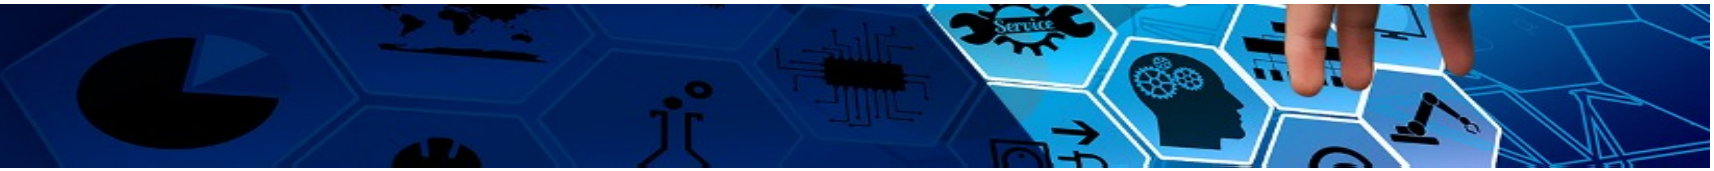
La tendance BIG DATA



Internet of Documents → Internet of Commerce → Internet of Applications → Internet of People → Internet of things


What
the
.....?

Le NoSQL



- Une nouvelle famille de SGBD capable de proposer :
  - Un modèle de données sans schéma/structure imposé.
  - Des temps de réponse très faible quelque soit la volumétrie.
  - Conçu principalement sur une architecture horizontale.
  - Des traitements complexes qui sont difficiles à réaliser par les SGBDR.
- Le nombre de SGBD NoSQL va exploser dans les années 2000.

Le NoSQL

Orienté Clé-Valeur

Key		Value
City	→	Denver
State	→	Colorado
Country	→	USA

Orienté Colonne

train6101	PARIS 06:07	VALENCE 08:19	AVIGNON 09:07	AIX 09:30	MARSEILLE 09:41
train2917			AVIGNON 11:30		11:59 MARSEILLE

Orienté Document

```
{
  first_name: 'Paul',
  surname: 'Miller',
  cell: 447557505611,
  city: 'London',
  location: [45.123,47.232],
  Profession: ['banking', 'finance', 'trader'],
  cars: [
    { model: 'Bentley',
      year: 1973,
      value: 100000, … },
    { model: 'Rolls Royce',
      year: 1965,
      value: 330000, … }
  ]
}
```

Fields

String

Number

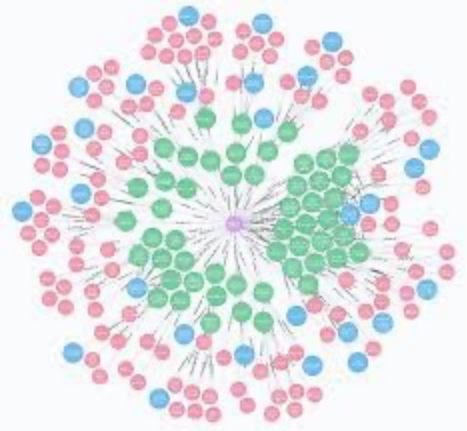
Geo-Coordinates

Typed field values

Fields can contain arrays

Fields can contain an array of sub-documents

Orienté Graphe



Le NewSQL

- « Many enterprise systems that handle high-profile data (e.g., financial and order processing systems) also need to be able to scale but are unable to use NoSQL solutions because they cannot give up strong transactional and consistency requirements. »
- Google se plaint que ses développeurs passent trop de temps à gérer l'intégrité des données dans le code applicatif.
- Nouvelles plateformes. Développements « from scratch »
- A partir de 2011, naissance des bases de données NEWSQL
  - Google Spanner (successeur de BigTable)
  - VoltDB
  - H-Store



Les bases de données vectorielles



Une base de données vectorielle est une base de données spécialement conçue pour stocker, indexer et rechercher efficacement des vecteurs, généralement composés d'un grand nombre de dimensions.

Mais pourquoi représenter des données sous forme de vecteurs ?

Des objets tels que des textes, documents, images, sons ou vidéos peuvent être transformés par un modèle en une représentation numérique appelée embedding.
Un embedding représente un objet par un vecteur dans un espace à N dimensions, de manière à capturer certaines de ses caractéristiques ou propriétés sémantiques.

Dans cet espace, plus les vecteurs sont proches, plus les objets qu'ils représentent sont considérés comme similaires, selon la représentation apprise par le modèle.
Ainsi, plutôt que de rechercher uniquement une correspondance exacte sur des mots, il devient possible de rechercher des objets sémantiquement similaires.

C'est ce principe qui permet notamment de réaliser de la recherche sémantique, de rechercher des images similaires, de construire des systèmes de recommandation ou encore d'alimenter des architectures RAG (Retrieval-Augmented Generation) utilisées avec les LLM.

1 Données à stocker

Différents types de contenus

- **Textes** (articles, documents, FAQ, ...)
- **Images** (photos, schémas, ...)
- **Sons** (chansons, enregistrements, ...)
- **Vidéos** (films, tutoriels, ...)

2 Génération des embeddings

Un modèle transforme chaque contenu en un vecteur numérique

Modèle d'IA
(ex : modèle d'embedding)

[0.12, -0.45, 0.81, ...]
[0.03, 0.67, -0.21, ...]
[-0.31, 0.22, 0.44, ...]
[0.55, -0.18, 0.09, ...]

3 Stockage dans une base vectorielle

Les embeddings sont stockés et indexés pour permettre une recherche efficace

Base de données vectorielle

[0.12, -0.45, 0.81, ...]
[0.03, 0.67, -0.21, ...]
[-0.31, 0.22, 0.44, ...]
[0.55, -0.18, 0.09, ...]

4 Recherche vectorielle

On transforme la requête en vecteur et on recherche les vecteurs les plus proches

Requête utilisateur

« voiture électrique »

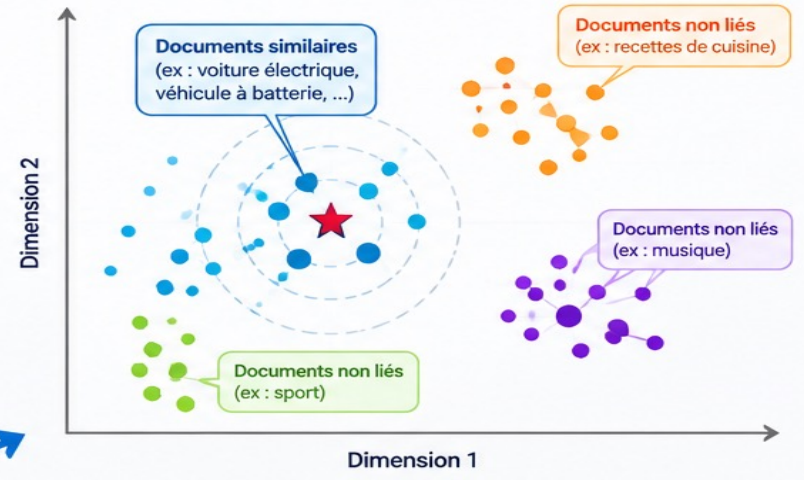
Modèle d'IA
(même modèle d'embedding)

Vecteur de la requête

[0.28, -0.31, 0.76, ...]

Recherche des plus proches voisins
(similarité vectorielle)

Espace vectoriel (exemple en 2D pour la visualisation)



Vecteur de la requête
Résultats similaires (vecteurs proches)
Autres documents (vecteurs plus éloignés)

Résultats

Les objets les plus proches sont renvoyés



Voiture électrique : guide complet
Découvrez les avantages des véhicules électriques ...
Score : 0,92



Véhicule à batterie : comment ça fonctionne ?
Un véhicule à batterie utilise ...
Score : 0,87



Comparatif des voitures électriques en 2024
Tesla, Renault, Hyundai ...
Score : 0,83

...

1 Données à stocker

Différents types de contenus

- **Textes** (articles, documents, FAQ, ...)
- **Images** (photos, schémas, ...)
- **Sons** (chansons, enregistrements, ...)
- **Vidéos** (films, tutoriels, ...)

2 Génération des embeddings

Un modèle transforme chaque contenu en un vecteur numérique

Modèle d'IA
(ex : modèle d'embedding)

[0.12, -0.45, 0.81, ...]
[0.03, 0.67, -0.21, ...]
[-0.31, 0.22, 0.44, ...]
[0.55, -0.18, 0.09, ...]

3 Stockage dans une base vectorielle

Les embeddings sont stockés et indexés pour permettre une recherche efficace

Base de données vectorielle

[0.12, -0.45, 0.81, ...]
[0.03, 0.67, -0.21, ...]
[-0.31, 0.22, 0.44, ...]
[0.55, -0.18, 0.09, ...]

4 Recherche vectorielle

On transforme la requête en vecteur et on recherche les vecteurs les plus proches

Requête utilisateur

« voiture électrique »

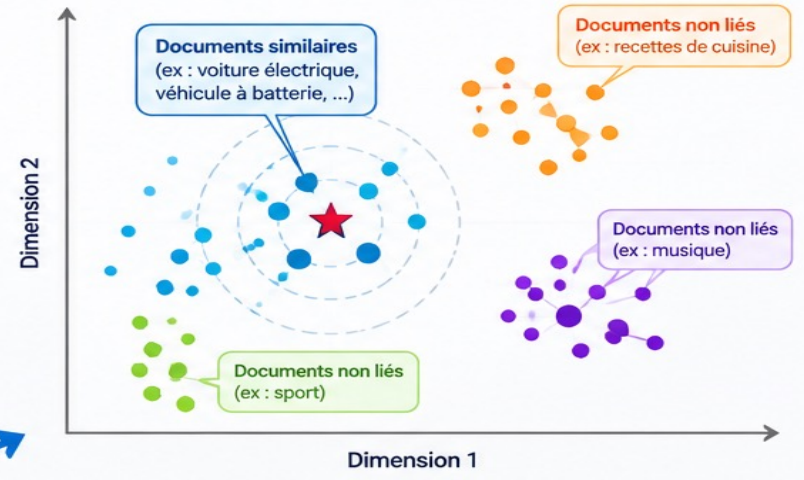
Modèle d'IA
(même modèle d'embedding)

Vecteur de la requête

[0.28, -0.31, 0.76, ...]

Recherche des plus proches voisins
(similarité vectorielle)

Espace vectoriel (exemple en 2D pour la visualisation)



Vecteur de la requête
Résultats similaires (vecteurs proches)
Autres documents (vecteurs plus éloignés)

Résultats

Les objets les plus proches sont renvoyés



Voiture électrique : guide complet
Découvrez les avantages des véhicules électriques ...
Score : 0,92



Véhicule à batterie : comment ça fonctionne ?
Un véhicule à batterie utilise ...
Score : 0,87

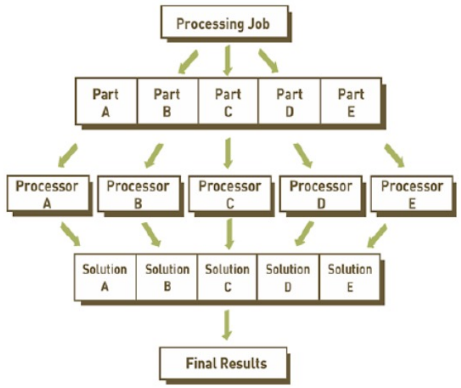


Comparatif des voitures électriques en 2024
Tesla, Renault, Hyundai ...
Score : 0,83

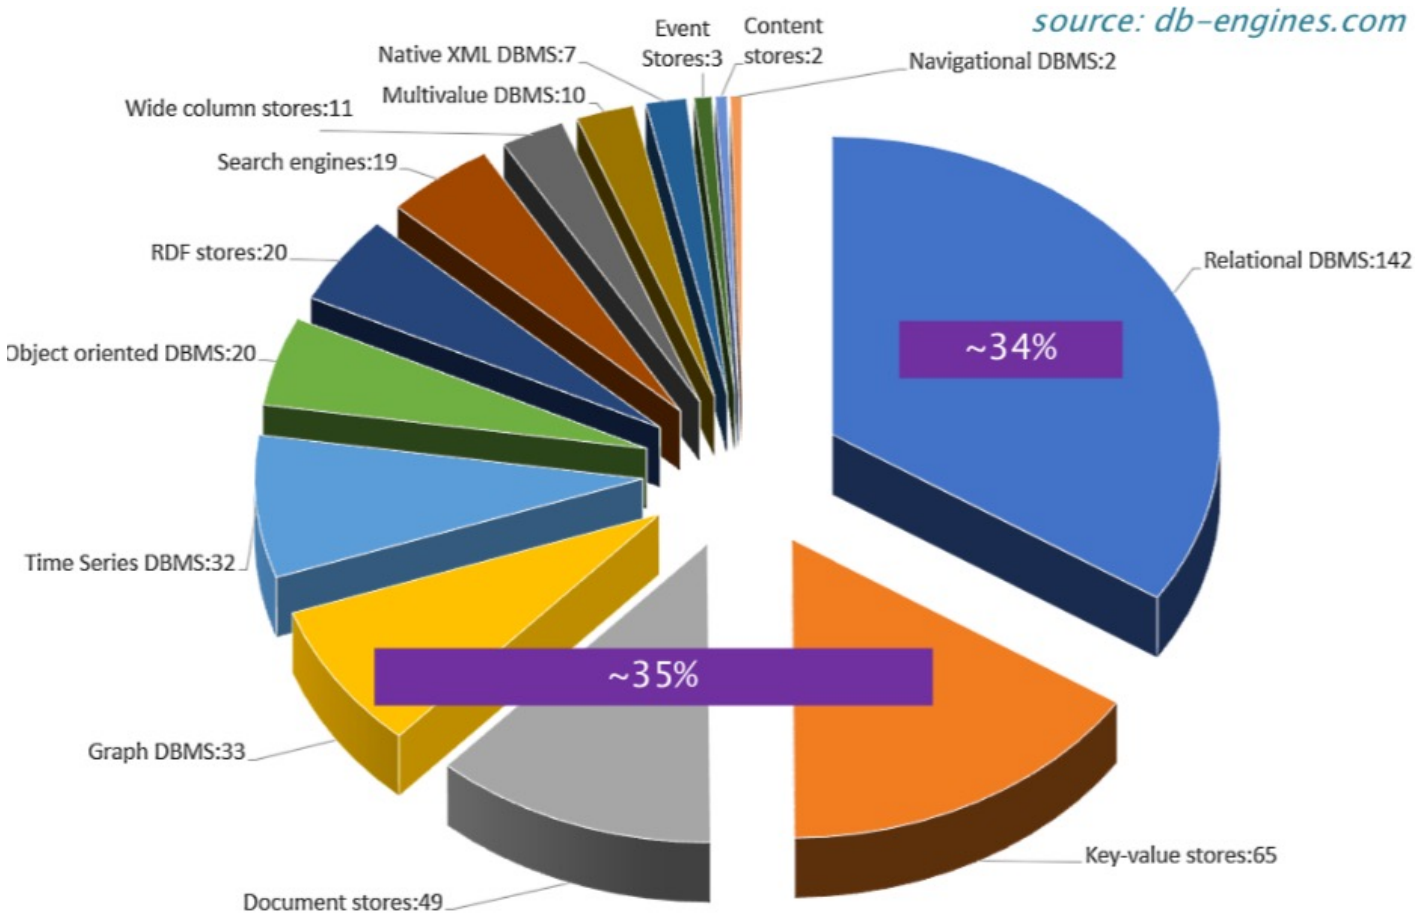
...

L’écosystème BIG DATA

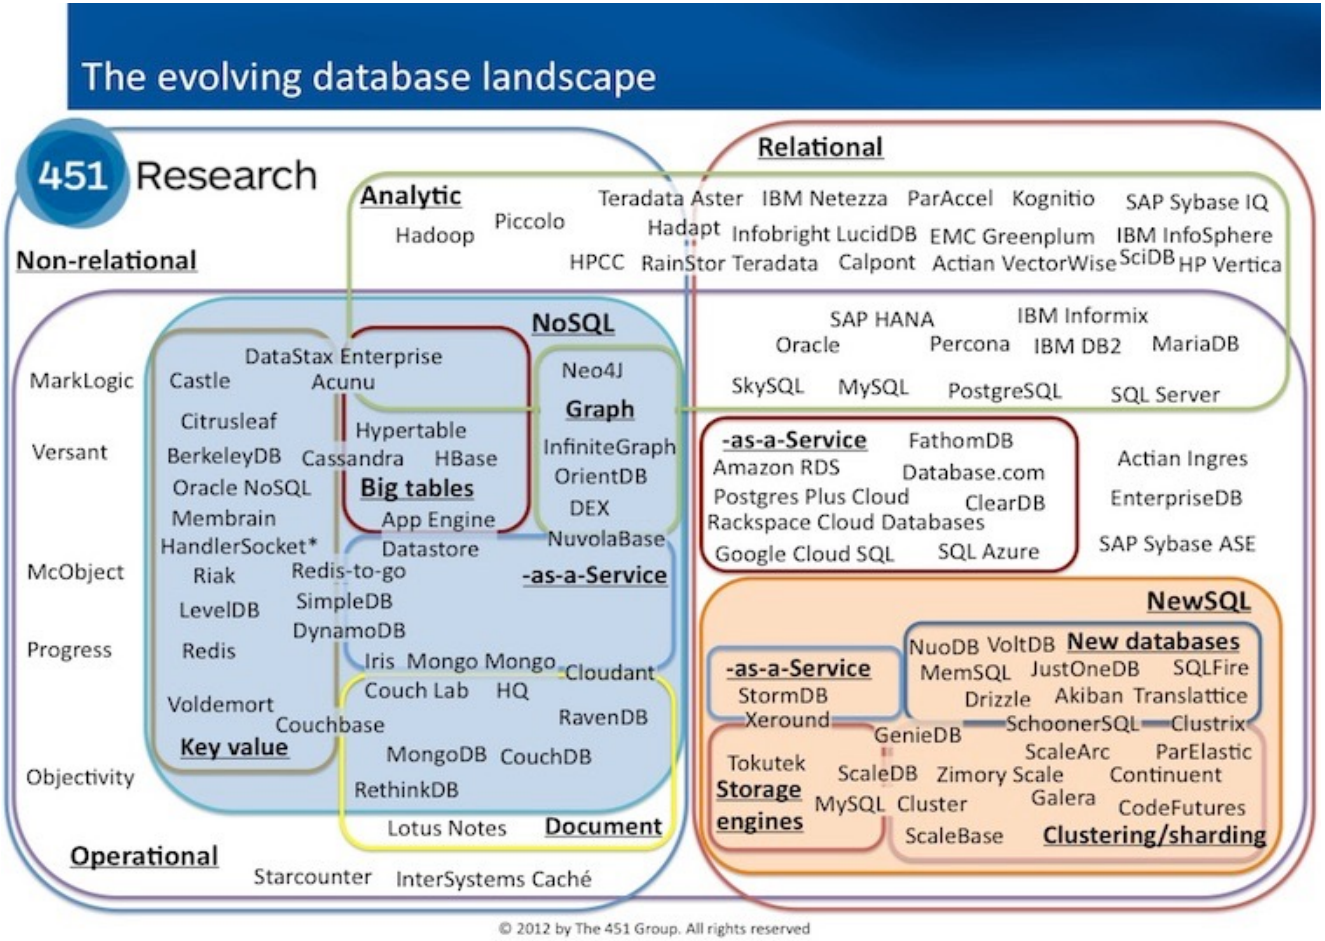
- Pour les traitements de données complexes, des nouvelles plateformes émergent.
  - Naissance en 2011de la première plateforme de traitement parallélisée Open-source : HADOOP
  - Avec un système de stockage distribué HADOOP Distributed File System très très similaire à GoogleFS
  - Un modèle de traitement basé sur le paradigme Map-Reduce.



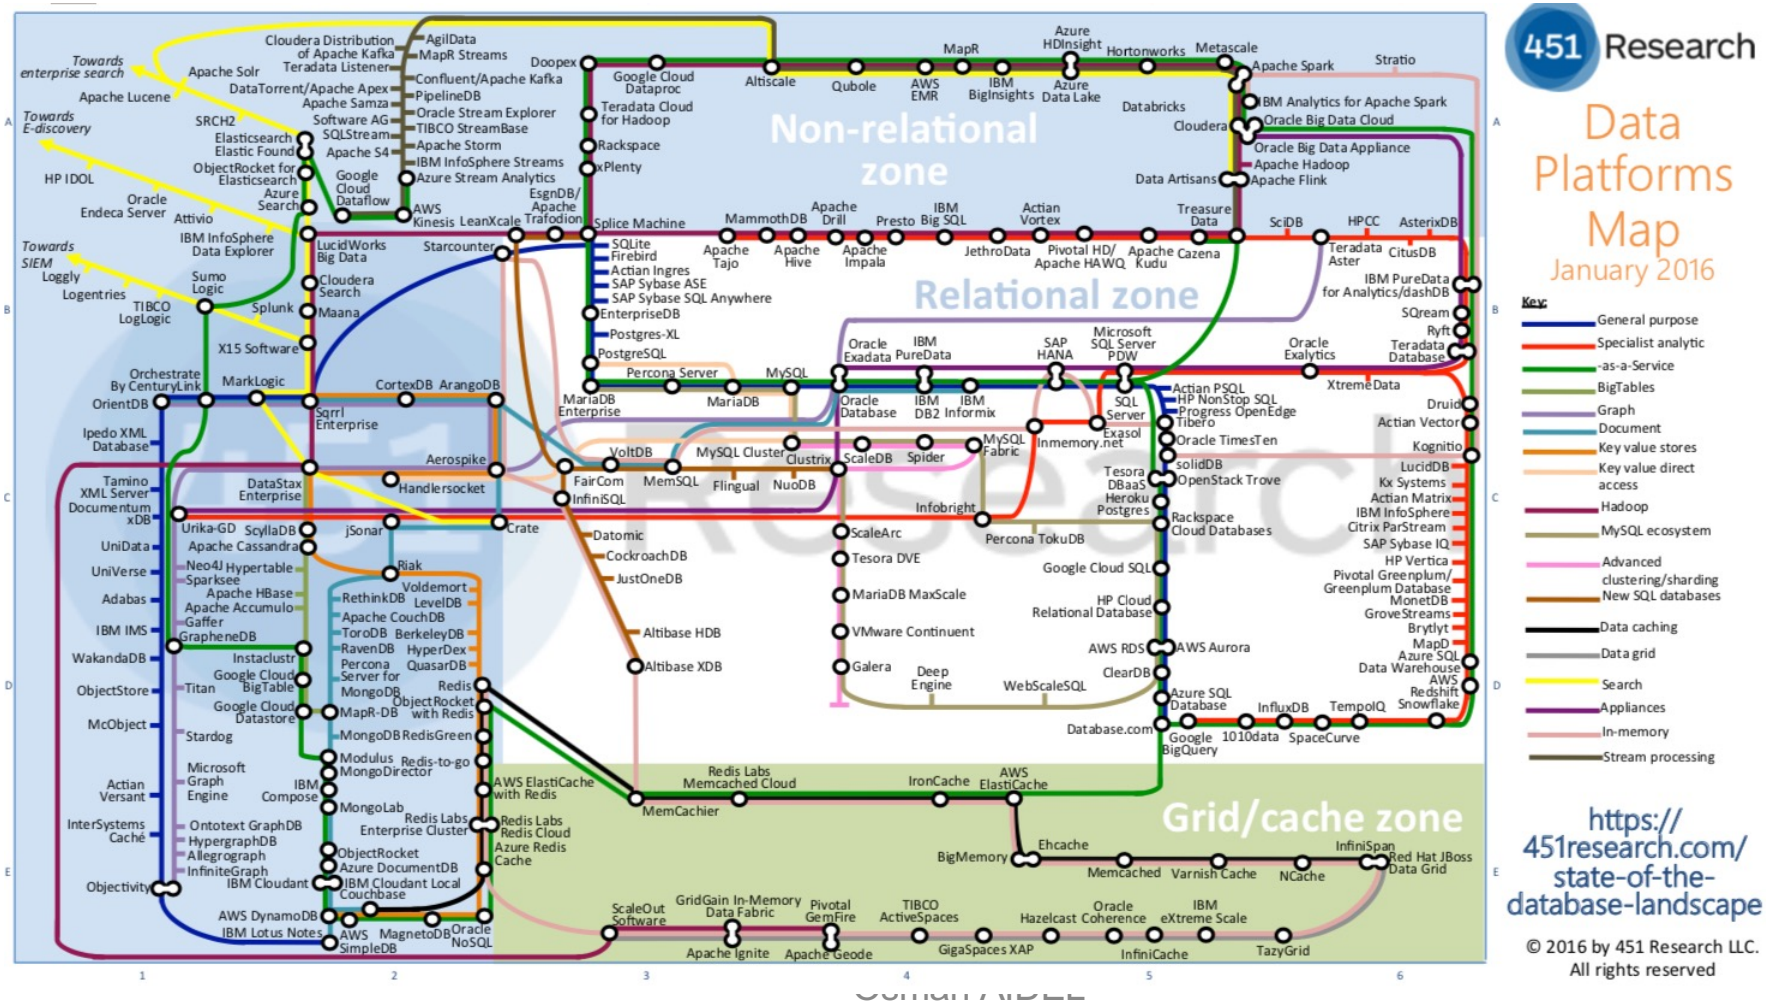
Le NoSQL aujourd'hui (415 DB)



Vision des bases de données en 2012



Vision des plateformes de données en 2016



451 Research

Data Platforms Map

January 2016

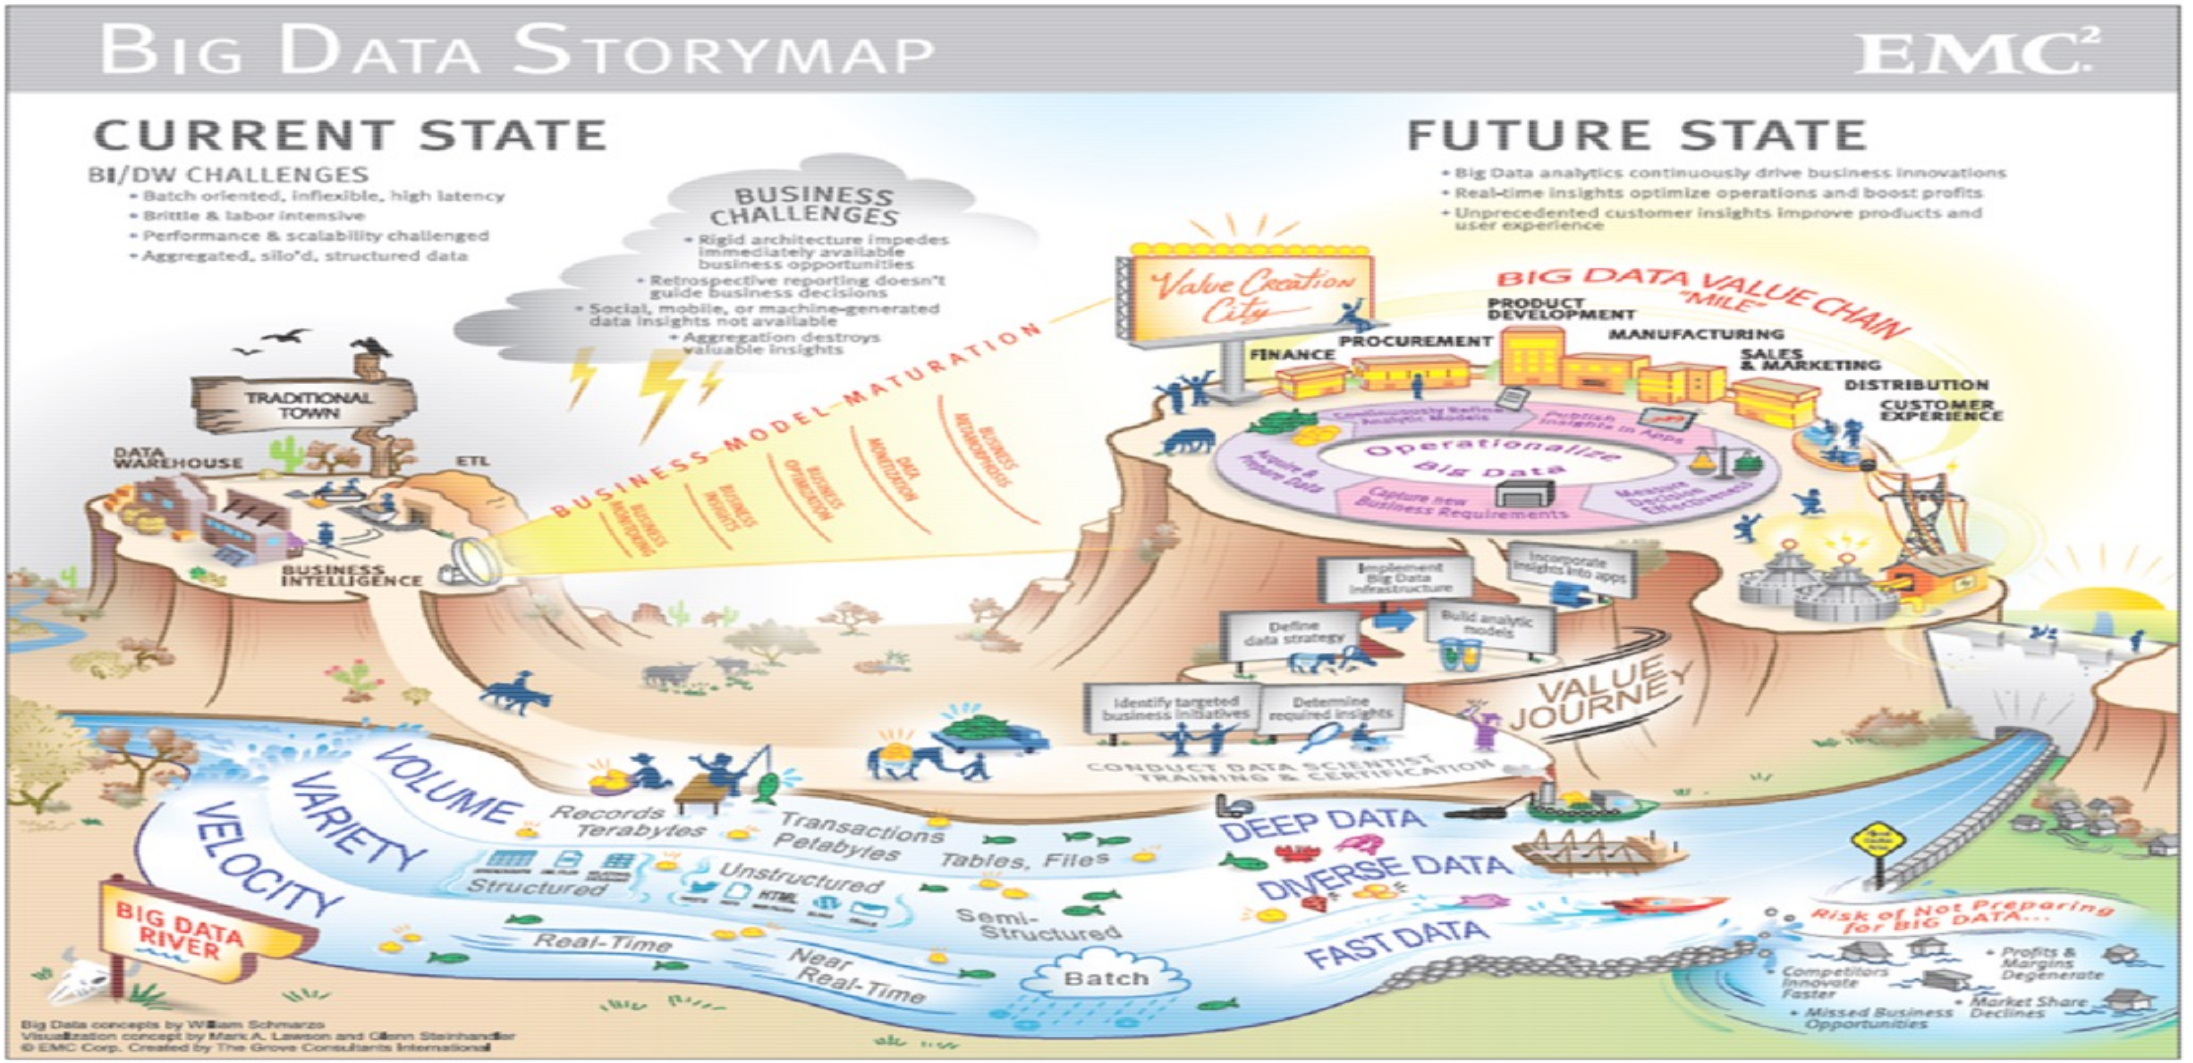
Key:

- General purpose
- Specialist analytic
- -as-a-Service
- BigTables
- Graph
- Document
- Key value stores
- Key value direct access
- Hadoop
- MySQL ecosystem
- Advanced clustering/sharding
- New SQL databases
- Data caching
- Data grid
- Search
- Appliances
- In-memory
- Stream processing

https://451research.com/state-of-the-database-landscape

© 2016 by 451 Research LLC. All rights reserved

Le futur ?


BIG DATA STORYMAP
EMC²
CURRENT STATE
BI/DW CHALLENGES
• Batch oriented, inflexible, high latency
• Brittle & labor intensive
• Performance & scalability challenged
• Aggregated, silo'd, structured data
BUSINESS CHALLENGES
• Rigid architecture impedes immediately available business opportunities
• Retrospective reporting doesn't guide business decisions
• Social, mobile, or machine-generated data insights not available
• Aggregation destroys valuable insights
BUSINESS-MODEL-MATURATION
TRADITIONAL TOWN
DATA WAREHOUSE
ETL
BUSINESS INTELLIGENCE
FUTURE STATE
• Big Data analytics continuously drive business innovations
• Real-time insights optimize operations and boost profits
• Unprecedented customer insights improve products and user experience
Value Creation City
BIG DATA VALUE CHAIN "MILE"
PRODUCT DEVELOPMENT
FINANCE
PROCUREMENT
MANUFACTURING
SALES & MARKETING
DISTRIBUTION
CUSTOMER EXPERIENCE
Operationalize Big Data
Acquire & Prepare Data
Capture New Business Requirements
Implement Big Data Infrastructure
Incorporate Insights into Apps
Define data strategy
Build analytic models
Identify targeted business initiatives
Determine required insights
CONDUCT DATA SCIENTIST TRAINING & CERTIFICATION
VALUE JOURNEY
VOLUME
VARIETY
VELOCITY
BIG DATA RIVER
Records Terabytes
Transactions Petabytes
Tables, Files
Structured
Unstructured
Semi-Structured
Real-Time
Near Real-Time
Batch
DEEP DATA
DIVERSE DATA
FAST DATA
Risk of Not Preparing for BIG DATA...
Competitors Innovate Faster
Profits & Margins Degenerate
Missed Business Opportunities
Market Share Declines
Big Data concepts by William Schmarzo
Visualization concept by Mark A. Lawson and Glenn Steinhandler
© EMC Corp. Created by The Grove Consultants International